



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

参赛队号

	1.
队员姓名	2.
	3.

中国研究生创新实践系列大赛 “华为杯”第二十三届中国研究生 数学建模竞赛

题 目：算力约束下提升大语言模型能力的资源配置建模

摘 要

本文针对大语言模型训练中的数据质量、数据配比、标度关系、算力配置与未来能力情景，建立一套按来源分层、按资格解释的统一建模框架。问题一以 A1 至 A3 的 272505 条物理记录为基础，按联合键去重得到 261086 个唯一键；其中 261067 条满足 11 个主质量特征的严格完整案例条件。主质量分采用组内等权、三组等权的冻结规则，定位为可复现的操作性质量代理。扩展冲突检验中 A2 与 A3 分别通过 1/4 和 3/4 个全局判据，资格为部分稳定；作者盲审的总体质量相关为 $n=47$ 、Spearman $\rho=0.032696$ 、95% bootstrap 区间为 $[-0.253384, 0.315957]$ ，没有形成稳定正向一致性。因此，质量分不解释为人工真值或跨域语义金标准。

关键词：大语言模型；数据质量；条件标度律；算力约束；资源配置；未验证情景

问题二以 B1 来源内模型为基础，冻结得到 $E=1.6897976$ 、 $A=0.3539803$ 、 $B=1.2403056$ 、 $\alpha=0.3399766$ 、 $\beta=0.2798781$ ，并在 $N_B \in [0.070542, 11.965825]$ 、 $D_B \in [0.134, 299.893]$ 的支持框内解释。分来源验证显示，B3 同源 Pythia 插值获得支持，B2、B4 和 B5 验证失败，B9 仅为超支持域压力样本，B10 仅为估算情景。B6 的 $k_{add}=0.3544081$ 只在该来源及 $0.1 \leq Q_score \leq 0.6$ 内成立。由此，本文采用“分层估计、联合表达”的条件广义标度律，而不把参数规模、数据量、质量和配比写成已经统一识别或多源验证的四变量模型。问题三保持冻结，不重新优化。在 $M0_B1$ 、 $H=2048$ 、 Q 不识别且不优化、 p 固定为 p_0 的条件下， $1e18$ 、 $1e20$ 、 $1e22$ FLOPs 的条件最优 $(N_B, D_B, Loss)$ 分别为 $(0.078248576, 1.993850677, 3.553996156)$ 、 $(0.625922700, 24.925757775, 2.609142026)$ 和 $(5.202388053, 299.893000000, 2.143211279)$ 。最后一档的数据量达到 B1 支持上界，因此结果只表示冻结模型、支持域和外生上下文下的条件最优。问题四在 25 个预训练开放权重模型、10 个模型族上直接建模 Benchmark。IFEval 与 MUSR 选择常数模型，BBH、MATH Lvl 5、GPQA、MMLU-PRO 及六任务辅助均值选择规模模型；所有带时间项模型均未通过预注册升级门槛。冻结端点窗口包含相同的 23 个 compute 有效模型，因此规模与非规模端点增量均为 0，比例不可定义；该结果不能解释为规模没有作用。以 2025-01-28 为情景原点，本文报告 2026-01-28 与 2027-01-28 的慢速、基准和上限敏感性数值。所有数值均为未验证情景；多数任务随时距增加而下降来自未通过升级门槛模型中的负时间项，不能写成已验证预测、负规模斜率或能力必然下降。Loss 到 Benchmark 的数值转换次数为 0。本文的主要贡献是把来源内估计、跨来源情景、不可识别量与冲突证据分开，并在每个结果旁保留支持域、有效分母和资格。该框架既给出可复核的资源配置结论，也避免把操作性代理、失败验证和未验证情景升级为更强的科学主张。

关键词：

目录

- 1 引言
- 2 问题重述与总体思路
- 3 数据 假设与符号
- 4 问题一 数据质量评价与领域配比
- 5 问题二 条件广义标度律
- 6 问题三 算力预算下的条件优化
- 7 问题四 Benchmark 分解与未来情景
- 8 统一验证与灵敏度

- 9 模型评价
- 10 改进与推广
- 11 结论
- 12 参考文献
- 13 附录与复现说明

1 引言

大语言模型训练同时受参数规模、训练数据量、数据质量、领域配比和算力预算约束。经典标度律以参数量和 token 数解释验证损失的经验变化〔REF-01〕〔REF-02〕，但这些关系通常不能直接回答质量信号是否可迁移、领域配比能否跨尺度运输，以及有限预算应如何在不同资源之间分配。下游 Benchmark 还引入另一层困难：交叉熵损失与任务得分来自不同观测体系，相关关系不自动构成可迁移预测桥。

本文按证据来源和识别资格组织四问。问题一先建立 A 侧质量代理与配比模型；问题二冻结 B1 来源内标度模型，并将质量与配比放入来源分层表达；问题三在已冻结的 B1 模型和支持域内求条件最优 N 与 D；问题四直接使用 Benchmark 数据选择任务级模型，并将未来结果限定为预注册数学网格下的未验证情景。全文不把弱人工相关、外部验证失败、支持域外压力样本或带时间项的未升级模型改写成肯定性结论。

2 问题重述与总体思路

2.1 问题一

问题一要求统一不同方向和类型的质量指标，识别指标冲突，形成样本级质量评价，并研究 17 维领域配比与 13 个验证领域损失之间的关系。关键约束是：缺失记录不能被填零掩盖；扩展集与抽样集的稳定性必须单独检查；人工盲审只能按实际成对有效分母统计。

2.2 问题二

问题二要求在参数规模 N 、数据量 D 、质量 Q 和配比 p 之间建立广义关系，并给出边际效用、弹性和替代条件。A 侧质量与 B 侧质量没有配对标定，RegMix 配比与 B1 标度实验也不在同一来源，因此正式模型采用分层估计和联合表达，避免把跨来源情景误写成联合拟合。

2.3 问题三

问题三要求在总算力预算下配置 N 、 D 、 Q 和 p 。冻结结果已经确定正式主情景只优化 N 与 D ， H 外生给定， Q 为未识别且未优化， p 固定为 p_0 。质量成本、配比运输和方向冲突只进入敏感性情景，不改变主结果。

2.4 问题四

问题四要求区分规模与非规模进步，并给出未来 12 个月和 24 个月的能力情景。本文分别处理直接 Benchmark 模型、Loss-Benchmark 桥接、历史 compute 增长识别和未来数学网格。直接 Benchmark 情景的原点固定为 2025-01-28；历史 compute 增长不可识别的旧接口日期不用于这些数值情景。

2.5 技术路线

全文采用四层证据结构：来源内条件关系、跨来源情景、不可识别量和冲突证据。每一层分别给出数据分母、支持范围、验证结果和资格。模型建立后依次执行分母审计、单位审计、支持域审计、独立复算和资格一致性检查。

图 1 四问数据流、冻结接口与资格分层技术路线 [FIG-00 待接入]

3 数据、假设与符号

3.1 数据来源与分母

A1 至 A3 合计 272505 条物理记录，按 (id, sub_path) 去重后得到 261086 个唯一键。主质量分要求 11 个特征全部有限且可用，得到 261067 条有效记录和 19 条缺失记录。领域配比支路使用 17 维非负单纯形输入和 13 个验证领域损失；1M 数据用于同尺度检验，60M 与 1B 只用于跨尺度运输诊断，10B 与 70B 为估算情景。

B1 提供参数规模与数据量的来源内标度数据，经验支持框为 $N_B \in [0.070542, 11.965825]$ 、 $D_B \in [0.134, 299.893]$ 。B6 提供 $0.1 \leq Q_score \leq 0.6$ 范围内的来源内质量关系。B2、B3、B4、B5、B9 和 B10 具有不同数据性质，必须分别验证，不能合并计算总 RMSE。

问题四直接 Benchmark 主样本包含 25 个预训练、开放权重、许可和身份明确的模型，覆盖 10 个模型族。C1 与 C2 的共同 4576 行在容差内等价，只视为同一批观测。端点分解对 M1 任务使用 23 个 compute 有效模型；M0 任务不使用规模中心。

3.2 模型假设

1. 不同来源保留 observed、semisynthetic、interpolated、estimated 等原始性质，不因进入同一流程而视为同质证据。
2. N_B 和 D_B 分别以十亿参数和十亿 token 表示；算力公式使用物理 N 与 D ，代入前必须乘以 10^9 。
3. $Q_baseline$ 只对 11 个主特征完整的记录定义。缺失记录保留，但不填零、不重分配权重。
4. 主质量分采用三个可解释组的组内等权和组间等权。该规则用于可复现聚合，不代表人工真值。
5. A2 与 A3 的扩展冲突资格固定为 PARTIALLY_STABLE；共同有效域不足时，域级门槛为 NOT_EVALUABLE。
6. 作者盲审在 sampling seal 后完成；无效或缺失评分不修复、不插补、不重抽样。
7. M0_B1 只在 B1 来源和经验支持框内解释；跨来源验证失败不触发重拟合。
8. B6 的加法质量项只在 B6 来源与冻结质量范围内成立；A 侧 Q 与 B 侧 Q_score 不进行无证据标定。
9. 配比运输只作为情景。固定领域质量向量时， $Q_mix = p^T q$ 位于 p 的列空间，因此 Q 与完整 p 不作为独立自由坐标同时解释。
10. 问题三正式主情景只优化 N_B 与 D_B ； Q 为 NOT_IDENTIFIED_NOT_OPTIMIZED， p 为 FIXED_P0_NOT_OPTIMIZED。
11. 问题四的任务模型分别选择 M0 或 M1；M2 在所有任务和辅助均值上均未通过升级门槛。
12. 问题四的未来 compute 增长率来自冻结的 1.0、1.5、2.0 年乘数数学网格，不是历史估计。
13. 未来数值全部为 SCENARIO_ONLY_UNVALIDATED；Loss-Benchmark 桥接保持 CONDITIONAL_ASSOCIATION_ONLY，且不参与直接 Benchmark 数值计算。

3.3 主要符号

表 1 主要符号与资格

符号	含义	单位或范围	资格
N_B	参数规模	十亿参数	B1 支持框内解释
D_B	训练数据量	十亿 token	B1 支持框内解释
Q_baseline	A 侧主质量分	0 至 1	操作性质量代理
Q_score	B6 质量水平	0.1 至 0.6	B6 来源内
p	17 维领域配比	非负且和为 1	Q1 来源内
L	交叉熵验证损失	Loss	B 侧输出
H	上下文长度	2048 至 131072 的冻结集合	外生变量
C	总训练计算量	FLOPs	问题三预算
b_C	Benchmark 对 $\log_{10}(\text{compute})$ 的斜率	Benchmark 点	M1 来源内
Δ_{scale}	冻结端点规模增量	Benchmark 点	本次为 0
$\Delta_{\text{non_scale}}$	冻结端点非规模增量	Benchmark 点	本次为 0

4 问题一 数据质量评价与领域配比

4.1 质量代理的构造

质量处理依次完成字段审计、多维字段标量化、方向统一、归一化和分组聚合。设第 g 组包含 m_g 个方向统一后的特征 z_{gj} ，则记录 i 的组得分和主质量分定义为：

$$Q_{ig} = \frac{1}{m_g} \sum_{j=1}^{m_g} z_{igj}, Q_i = \frac{1}{3} \sum_{g=1}^3 Q_{ig} \quad (1)$$

三组先分别等权，再进行组间等权。该结构避免特征数量较多的组自动获得更高权重。任一主特征缺失时， $Q_{\text{valid}}=\text{False}$ ， Q_{baseline} 保持缺失。主结果得到 261067 条有效记录，覆盖率为 261067/261086；其余 19 条只保留在分母审计中。

主质量分是冻结信号下的操作性代理。它能支持同一处理规则下的排序、分层和敏感性比较，但不代表真实语义质量，也不因数值范围为 0 至 1 而获得人工标定含义。

4.2 冲突诊断与扩展稳定性

本文使用三个质量组之间的范围和标准差诊断冲突，并保持预先声明的等组权消解规则。扩展检验不重建主质量分，而是检查冲突现象在 A2 和 A3 是否保持。A2 的四个全局判据通过 1 个，A3 通过 3 个，共同资格为 PARTIALLY_STABLE；两者共同有效域均只有 1 个，低于预注册门槛，因此域级结论为 NOT_EVALUABLE。没有观察到一致方向反转，但也不能据此宣称跨域结构稳定。

图 2 主质量覆盖、扩展冲突稳定性与作者盲审效应量 [FIG-Q1-01 待接入]

4.3 作者盲审核验

抽样 seal 固定 60 个 review_id、7 个域和种子 20260925，评分发生在 seal 之后。作者表解析得到 46 条四项完整评分、1 条部分评分、10 条结构性无效记录和 3 条缺失记录。10 条无效记录包含越界候选且字段对齐无法无歧义恢复，因此不猜测修正。各统计量严格使用对应指标的成对有效分母。

表 2 作者盲审与质量代理的相关结果

核验项	有效分母	Spearman ρ	95% bootstrap 区间	解释
Q 与总体质量	47	0.032696	[-0.253384, 0.315957]	未显示稳定正向一致性
Q 与可读性	47	-0.293551	[-0.568145, 0.000325]	方向不稳定
Q 与完整性	47	0.055104	[-0.290693, 0.362965]	描述性结果
Q 与污染分	46	0.058878	[-0.252439, 0.371249]	污染分越低越好

表 2 的结果不用于重新选择特征或修改阈值。总体质量相关接近 0，可读性相关为负且区间触及 0，其他指标也没有稳定正向证据，因此人工核验只能作为质量代理解释边界的一部分。

4.4 领域配比模型

设 p 为 17 维训练领域配比, 满足 $p_j \geq 0$ 且 $\sum p_j = 1$; 对 13 个验证领域分别拟合线性损失响应。冻结同尺度 1M 检验中, 相对逐域训练均值基线的等域 MSE 改善为 55.03%, Spearman 为 0.62507。60M 与 1B 结果只用于跨尺度运输诊断, 10B 与 70B 仅为估算情景。因配比分量存在单纯形共线性, 单个系数不解释为 17 个相互独立的因果效应。

图 3 领域配比同尺度检验与跨尺度运输诊断 [FIG-Q1-02 待接入]

4.5 问题一结论

Q_{baseline} 在冻结信号和严格完整案例规则下可复现, 但扩展冲突仅部分稳定, 有限作者盲审没有显示稳定正向一致性。配比模型在 1M 同尺度检验中提供来源内支持, 跨尺度结果只构成运输诊断。由此, 问题一向后续问题提供质量代理、配比方向和明确的识别边界, 而不提供人工真值或无条件跨尺度参数。

5 问题二 条件广义标度律

5.1 B1 来源内主模型

正式主模型保持为参数规模与数据量的加性幂律：

$$L_0(N_B, D_B) = E + AN_B^{-\alpha} + BD_B^{-\beta} \quad (2)$$

冻结参数为 $E=1.6897975629820348$ 、 $A=0.3539803206065571$ 、 $B=1.2403055835426349$ 、 $\alpha=0.339976581941082$ 、 $\beta=0.2798781285468448$ 。参数资格为 IDENTIFIED_SOURCE_CONDITIONAL，只适用于 B1 与其经验支持框。

表 3 M0_B1 参数与支持框

参数	冻结值	解释资格
E	1.6897975629820348	B1 来源内不可约项
A	0.3539803206065571	B1 来源内参数项系数
B	1.2403055835426349	B1 来源内数据项系数
α	0.339976581941082	B1 来源内参数指数
β	0.2798781285468448	B1 来源内数据指数
N_B 支持	[0.070542, 11.965825]	超出范围为 OOS
D_B 支持	[0.134, 299.893]	超出范围为 OOS

5.2 分来源验证

验证按来源单独计算，不合并半合成、插值、公开观测和估算记录。B2、B4、B5 均保留失败结论；B3 的支持来自同源 Pythia 插值，不构成独立外部复制。B9 与 B10 的参数规模均为 100B 至 10000B，全部超出 B1 的 N_B 上界。

表 4 分来源验证结果

来源	原始记录	支持内/OOS	RMSE	最终资格
B2	1029	120/909	2.03943	VALIDATION_FAILED
B3	4000	4000/0	0.00382128	VALIDATION_SUPPORTED，同源插值
B4	57	8/49	0.411194	VALIDATION_FAILED
B5	44	8/36	0.201239	VALIDATION_FAILED
B9	132	0/132	不可计算真实误差	OOS_STRESS_ONLY
B10	128	0/128	0.00109383，仅对估算参考	ESTIMATED_SCENARIO_ONLY

B2 表现为系统性低估；B4 和 B5 的支持内样本及族数很少，仍不足以升级模型。所有失败结果都不因方向不利而被删除，也不触发主模型重拟合。

图 4 B1 来源内拟合与分来源验证 [FIG-Q2-01 待接入]

5.3 质量与配比的分层表达

B6 的来源内加法质量项定义为：

$$\Delta_Q(Q_B) = -k_{\text{add}}(Q_B - 0.6) \quad (3)$$

其中 $k_{\text{add}}=0.3544081081063713$ ，只在 B6 来源和 $0.1 \leq Q_{\text{score}} \leq 0.6$ 内成立。A 侧 Q_{baseline} 与 B 侧 Q_{score} 没有新增标定，映射 h_s 只使用冻结情景。配比项采用 RegMix 冻结系数 c 与参考配比 p_0 。正式联合表达为：

$$L_{\text{gen}}^s = L_0 + \rho_Q^s \Delta_Q(h_s(Q_A)) + \tau_p^s c^T (p - p_0) \quad (4)$$

上式的三个模块具有不同来源资格。L0 来源于 B1；质量项只在 B6 来源内识别，跨来源时为情景；配比项只在 RegMix 同尺度来源内具有支持，向 B1 运输为情景。因此， $L_{\text{gen}}^s(s)$ 是分层估计后的联合表达，不是统一联合拟合。

5.4 边际效用、弹性与替代条件

对 B1 主模型求偏导得到：

$$\frac{\partial L}{\partial N_B} = -\alpha A N_B^{-\alpha-1}, \frac{\partial L}{\partial D_B} = -\beta B D_B^{-\beta-1} \quad (5)$$

在工作点 $N_B=1$ 、 $D_B=100$ 时， $\partial L / \partial N_B = -0.120345$ ， $\partial L / \partial D_B = -0.000956624$ 。S03 的冻结条件下， $\partial L / \partial Q_A = -0.354408$ ；保持 Loss 不变的局部替代量约为 $dN_B / dQ_A = -2.94493$ 、 $dD_B / dQ_A = -370.478$ 。这些量只在相应来源与映射情景下成立，不能解释为跨来源因果替代率。

固定领域质量向量 q 时， $Q_{\text{mix}} = p^T T q$ 位于 p 的列空间；设计秩在加入 Q_{mix} 前后均为 17，相对投影残差为 $9.36888e-16$ 。因此， Q_{mix} 与完整 p 不作为两个独立自由坐标，解释时应固定其中一个或只报告联合可行方向。

5.5 问题二结论

M0_B1 在 B1 支持域内提供来源条件标度关系。外部验证包含失败、同源插值支持、OOS 压力和估算情景，不能概括为多源验证成功。质量与配比只通过分层模块进入联合表达，且没有改变问题三冻结数值输入。

6 问题三 算力预算下的条件优化

6.1 冻结优化问题

问题三保持 T07 冻结。主情景 S00_NULL_M0_B1 采用 $H=2048$ ，只优化 N_B 与 D_B 。物理量为 $N=10^9 N_B$ 、 $D=10^9 D_B$ ，总成本为：

$$C = 6ND + \eta NDH, N = 10^9 N_B, D = 10^9 D_B \quad (6)$$

其中 $\eta=2e-4$ 。主情景没有质量成本，Q 为 NOT_IDENTIFIED_NOT_OPTIMIZED，p 为 FIXED_P0_NOT_OPTIMIZED。约束包括预算上界、B1 支持框和变量非负条件。

6.2 三档预算结果

表 5 算力预算下的冻结条件最优配置

预算 FLOPs	最优 N_B	最优 D_B	预测 Loss	活跃边界
1e18	0.078248576	1.993850677	3.553996156	预算活跃，N/D 在支持内
1e20	0.625922700	24.925757775	2.609142026	预算活跃，N/D 在支持内
1e22	5.202388053	299.893000000	2.143211279	预算活跃，D 达到支持上界

1e22 结果受 D_B 上界支配，不能解释为无约束的真实最优数据规模。全部结果都是冻结模型、B1 支持域、指定预算和外生 H 下的条件最优，不是唯一全局真值。

图 5 三档预算下的冻结条件最优配置 [FIG-Q3-01 待接入]

6.3 数值验证与上下文敏感性

主表 75 行中 69 行为 OPTIMAL，6 行为 NO_NUMERIC_OPTIMUM。最大相对预算越界为 $9.403629568e-13$ ，最大 KKT residual 为 $2.7932317030401693e-08$ ，最大等式残差为 $9.403629568e-13$ 。数值解没有通过 clip 或扩大支持域获得。

临界上下文长度为 $H_{crit}=6/\eta=30000$ 。冻结 H 集合为 2048、4096、8192、32768、131072。 H 超过 30000 后，注意力项系数超过训练项；部分预算的活跃边界随 H 改变。这种变化只称为预注册活跃约束和弹性排序意义下的结构转移，不称为物理相变。

图 6 冻结上下文长度下的活跃约束敏感性 [FIG-Q3-02 待接入]

6.4 质量成本、配比与冲突情景

三类质量成本 G_{EXP} 、 G_{POWER} 和 G_{LOG} 均为假设比较，没有任何一种被识别为真实成本。S01 在参考点退化为 null；S03 在较大预算下选择质量上界，但配置和 Loss 依赖成本函数，资格为 SCENARIO_ONLY。S14、S15 和 S16 的配比结果只表示 RegMix 跨来源运输假设下的情景。S17 保持 NO_NUMERIC_OPTIMUM，B8 仅作为方向冲突证据。

6.5 参数不确定性

主模型使用 80 个 B1 整行参数 draw，不进行逐参数独立抽样。三档预算的 Loss 2.5%/50%/97.5% 分位分别为 3.553938/3.553994/3.554101、2.609105/2.609142/2.609161 和 2.143193/2.143212/2.143228。质量情景使用 200 个 B1/B6 条件整行组合，标记为 NOT_JOINT_POSTERIOR，不分配情景概率。

7 问题四 Benchmark 分解与未来情景

7.1 直接 Benchmark 建模口径

主样本包含 25 个预训练、开放权重、许可和身份明确的模型，覆盖 10 个模型族。compute 优先采用直接观测；只有 N 与 D 同时为观测值时才使用 6ND。C1 只用于与 C2 做等价和原字段审计，二者共同 4576 行不重复计数。Loss-Benchmark 桥接保持 CONDITIONAL_ASSOCIATION_ONLY，直接 Benchmark 模型没有使用 Loss，数值转换次数为 0。

对每个任务预注册 M0_CONSTANT、M1_SCALE 和 M2_SCALE_TIME 三个嵌套规格：

IFEval 与 MUSR 选择 M0；BBH、MATH Lvl 5、GPQA、MMLU-PRO 及辅助均值选择 M1。所有 M2 都没有通过冻结升级门槛，因此 M2 只用于前沿情景，资格为 SCENARIO_ONLY_UNVALIDATED。

表 6 任务级模型选择与端点分解

任务	选中模型	M1 的 b_C	Δ_{scale}	Δ_{non_scale}
IFEval	M0_CONSTANT	-	0	0
BBH	M1_SCALE	8.015483	0	0
MATH Lvl 5	M1_SCALE	3.704133	0	0
GPQA	M1_SCALE	2.883141	0	0
MUSR	M0_CONSTANT	-	0	0
MMLU-PRO	M1_SCALE	9.616437	0	0
六任务均值	M1_SCALE	4.499295	0	0

五个 M1 目标的规模斜率均为正。M2 未升级不改变 M1 的来源内规模关联结论，也不使 M2 的时间项获得验证资格。

7.2 端点规模与非规模分解

冻结起点为 2024-06-17，终点为 2025-01-28。对需要规模中心的 M1 任务，正负 365 天窗口包含完全相同的 23 个 compute 有效模型，集合对称差为 0；M0 任务不使用规模中心。因选中 M1 没有时间项、M0 没有规模或时间项，七个目标的 Δ_{scale} 与 Δ_{non_scale} 均严格为 0，恒等误差为 0，比例记为 NOT_DEFINED。

这些零值来自冻结窗口定义与模型结构，不能解释为规模没有作用。事实上，所有选中 M1 的 b_C 都为正。端点分解回答的是冻结窗口中可识别的拟合增量，不是对长期机制的否定。

7.3 未来 12 个月与 24 个月情景

直接 Benchmark 情景原点为 2025-01-28，12 个月和 24 个月时点分别为 2026-01-28 与 2027-01-28。慢速、基准和上限敏感性增长率来自 1.0、1.5、2.0 年乘数数学网格，不

是历史数据估计。表中数值单位为 Benchmark 点，全部资格为 SCENARIO_ONLY_UNVALIDATED。

表 7 未验证的 12 个月和 24 个月 Benchmark 情景

任务	12 个月 SLOW/BASELINE/UPPER	24 个月 SLOW/BASELINE/UPPER
IFEval	27.002799 / 27.647843 / 28.105508	26.676006 / 27.966093 / 28.881424
BBH	34.107388 / 35.451789 / 36.405656	23.122995 / 25.811797 / 27.719532
MATH Lvl 5	3.894673 / 4.913355 / 5.636120	-3.971072 / -1.933709 / -0.488178
GPQA	27.124326 / 27.668664 / 28.054879	22.076170 / 23.164847 / 23.937275
MUSR	32.876304 / 33.105237 / 33.267667	22.580095 / 23.037961 / 23.362822
MMLU-PRO	17.353537 / 19.145090 / 20.416216	4.422898 / 8.006002 / 10.548255
六任务均值	23.511163 / 24.414168 / 25.054860	16.214986 / 18.020997 / 19.302381

同一预测时点内，所有任务均满足 $SLOW \leq BASELINE \leq UPPER_SENSITIVITY$ 。多数任务从 12 个月到 24 个月下降，是未通过升级门槛的 M2 中负时间项绝对值大于正 compute 项所致。MATH Lvl 5 的 24 个月原始值保持为负；范围约束后的 0 只属于敏感性列，不替代主情景值。

图 7 六任务 12 个月和 24 个月三情景结果 [FIG-Q4-01 待接入]

7.4 不确定性与解释边界

问题四分别报告参数或重采样不确定性、模型选择不确定性、情景结构不确定性和时间外推不确定性，不合并为伪精确置信区间。family-out 与 group split 可评价；primary scale 子集的时间外测试少于 10 个模型，该协议为 NOT_EVALUABLE。历史 compute 增长继续为 NOT_IDENTIFIABLE，因此数学网格不能改写为估计增长率。

7.5 问题四结论

直接 Benchmark 结果支持部分任务的来源内正规规模关联，但不支持带时间项模型升级。端点零分解来自相同窗口样本和选中模型结构，不能解释为规模贡献为零。未来数值只表示预注册数学网格与未升级 M2 下的情景，不是经过验证的预测，也不与 Loss 空间数值互相换算。

8 统一验证与灵敏度

本文将验证分为五类。第一，分母验证确保物理记录、唯一键、完整案例和成对有效评分不混用。第二，单位验证确保十亿单位变量进入算力公式前转换为物理量。第三，支持域验证将 B1 内插、来源外推和估算场景分开。第四，数值验证复算预算、KKT 条件、预测公式和窗口分解。第五，资格验证检查摘要、正文、图题、表注和结论是否使用一致限定词。

Q1 的主要灵敏度来自冲突定义、扩展集和人工盲审；结果表明主质量分可复现，但人工一致性弱。Q2 的关键灵敏度来自来源差异；同源插值支持与公开跨族失败同时存在。Q3 的敏感性由 H、质量成本、配比运输和参数整行 draw 构成，均不改变主 null 的资格。Q4 的关键敏感性来自模型选择、时间项和情景网格；M2 未通过升级门槛，因此所有时间外数值保持未验证资格。

9 模型评价

9.1 优点

第一，模型链条保留了数据来源、支持域和有效分母，结果可以逐项回到冻结接口。第二，分层估计避免把不同来源强行合并，能够同时报告支持、失败、OOS 和估算结果。第三，问题三的成本单位、约束与 KKT 审计完整，条件最优解具有明确可行性证据。第四，问题四把直接 Benchmark 建模与 Loss 桥接隔离，避免未经识别的数值换算。

9.2 局限

Q_baseline 依赖操作性信号，有限作者盲审没有显示稳定正向一致性；扩展集也只达到部分稳定。B1 标度参数是来源内关系，B2、B4、B5 验证失败，B9 与 B10 全部超出支持域。A 侧 Q、B 侧 Q_score 和 RegMix 配比之间缺少共同实验设计，不能联合识别。

问题三的高预算解受到 D_B 上界约束；质量成本函数和配比运输系数都没有真实成本或跨来源因果含义。问题四主样本只有 25 个模型和 10 个族，带时间项模型未通过门槛，时间外协议部分不可评价。未来情景在训练时间范围外，且使用数学网格而非历史增长估计。以上限制共同决定了本文结论只能在冻结模型、支持域和情景合同内使用。

10 改进与推广

后续改进应优先补充已经封存抽样规则下的独立人工标签，并设计 A 侧与 B 侧可配对的质量干预实验；这类新数据可用于检验质量代理，而不是回填本轮无效评分。标度律方面，可在预先注册的支持域扩展中增加独立模型族和真实 Loss 观测，避免用估算值替代外部验证。Benchmark 方面，需要更长时间跨度、更多 compute 有效模型和真正的时间外测试，才可能把情景模型升级为预测模型。

在工程应用中，本框架适合作为资格感知的资源规划工具：来源内模型用于可支持的计算，跨来源映射只用于条件比较，OOS 与估算结果单独标记。任何新增数据都应先进入新的科学阶段和预注册验收流程，不能回写本轮冻结结果。

11 结论

本文完成了从质量代理、领域配比、条件标度律、算力优化到 Benchmark 情景的统一建模。问题一得到覆盖 261067 个唯一键的操作性质质量代理，但扩展冲突仅部分稳定，人工盲审没有显示稳定正向一致性。问题二冻结 B1 来源内标度模型，B3 同源插值获得支持，而 B2、B4、B5 外部验证失败；质量和配比只以分层模块进入联合表达。问题三在冻结 M0_B1、H=2048 和 B1 支持域内给出三档预算的条件最优 N_B 与 D_B，最高预算的数据量触及支持上界。问题四在直接 Benchmark 数据上选择任务级 M0 或 M1，所有 M2 均未通过升级门槛；端点分解为零来自窗口与模型结构，未来数值全部为未验证情景。

因此，本研究能够支持的是条件性资源配置与情景比较，而不是人工真值、统一四变量多源验证、唯一全局最优或已验证未来预测。把限定词与数值一同保留，是本模型可复核和可使用的前提。

12 参考文献

本候选稿保留以下稳定引用插槽，尚未接入经核验的最终参考文献资产。所有作者、题名、期刊、年份、卷期、页码和 DOI 必须由 `paper/final_references/` 的正式交付物填充，当前不自行补写。

1. (REF-01) 经典大语言模型标度律背景文献插槽，对应预检键 `kaplan2020scaling`。
2. (REF-02) 计算最优训练与参数数据配置文献插槽，对应预检键 `hoffmann2022training`。
3. (REF-03) Pythia 模型族与训练轨迹来源文献插槽，对应预检键 `biderman2023pythia`。
4. (REF-04) 大规模数据筛选与质量评价文献插槽，对应预检键 `penedo2024fineweb`。
5. (REF-05) 质量评价方法背景文献插槽，对应预检键 `zhuang2025metarater`。
6. (REF-06) 标度律解释与理论背景文献插槽，对应预检键 `bahri2024explaining`。

13 附录与复现说明

13.1 冻结接口

科学裁决以 paper/FINAL_SCIENTIFIC_FREEZE.md 为最高优先级，正文补丁以 paper/FINAL_PAPER_PATCH_CONTRACT.md 为准，结果索引为 paper/FINAL_RESULT_INDEX_V2.md。Q1、Q2、Q3、Q4 的最终主接口分别为 paper/Q1_GAP_RESULT_FREEZE.md、paper/Q2_GAP_RESULT_FREEZE.md、paper/T07_RESULT_FREEZE.md 和 paper/Q4_GAP_RESULT_FREEZE.md。

13.2 图表与引用接入

FIG 与 REF 的待接入项、固定编号、来源和验收条件列于同目录的 INTEGRATION_INBOX.md。接入时只替换稳定插槽，不改动冻结数字、模型选择、阈值或资格词。

13.3 AI 工具使用声明

AI 工具用于冻结接口整理、文字一致性检查、Word 排版和版面核验。所有科学数字与资格均来自项目冻结文件；本阶段没有新增实验、重拟合、阈值调整或模型搜索。最终提交时应按竞赛要求核对并完善正式声明文本。