

第二十三届中国研究生数学建模竞赛·华为杯

算力约束下提升大语言模型能力的资源配置建模

F 题·解题思路讲解

2026.09 | 时长约 20分钟

题目定位：算力有限，四类资源如何取舍？

核心矛盾

- 算力有限，扩大规模、提升质量、延长上下文都要花算力 → 资源如何配置？
- 上下文越长 → 注意力与 KV 缓存开销越高 → 挤压参数、数据、质量预算
- 领域配比不增总开销，却改变算力在各领域间的分配效果

四类决策资源


- N 参数量（脑容量） D 数据量（阅读量）
- Q 数据质量（教材质量） p 领域配比（课时分配）
- 目标链条：交叉熵 Loss → 标度律建模 → Benchmark 能力
- 背景：数据墙、OpenScholar-8B 超越 GPT-4o → Q 与 p 不可忽视

经典标度律（出发点）

$$L(N, D) = E + A \cdot N^{-\alpha} + B \cdot D^{-\beta}$$

E 不可约损失 · A、 α 、B、 β 待估参数 · 本题目标：把 Q、p 显式纳入其中

四问主线：严格递进，前一问输出是后一问输入



数据全景：三大附件，真实为主、半合成须标注

附件	内容与规模	解题要点
A 数据价值	质量信号 A1 抽样 5.1 万条 + A2/A3 扩展 22 万条；配方实验 A4–A15 (512 训练组 + 三尺度检验 + 外推)	22 指标含 8 个列表型须压缩；17 配方域中 4 域无 Loss 列；A16 提供域映射 (6 直连 + 11 推断)
B 标度律	B1 Pythia 训练日志 1,176 点 (0.07–12B) ； B2–B5 验证； B6–B8 N-D-Q 实验 (360/450/1704 点) ； B9/B10 大模型	B6–B8 是唯一含 Q 的标度数据； B2、 B6–B8、 B10 为半合成/估算，必须标注可信度边界
C 评测演进	C1 榜单 4,576 行 × 6 维得分； C6 Loss–Benchmark 桥接 75 条 (7 条高可比) ； C7 架构 (含上下文长度) ； C8 逐任务 JSON	桥接按可比性分层使用； C8 必做逐任务聚合； Type 须区分 pretrained 与 chat

提醒

- 《数据说明》页脚重复出现的"方法建议"已实测证伪多处 (如"Loss 与 Benchmark 正相关", 实测 ≈ -0.51) , 所有结论必须自行核验。

三个子任务：质量评价 → 冲突消解 → 配比建模

① 数据质量评价

- 22 个维度合成为综合质量分 Q
- 样本级 → 语料级 → 域级聚合，并对照抽样集
- 指标方向统一为“越高越好”

② 质量冲突消解

- 定义冲突、分析成因、给出消解规则
- 抽样集定规则，扩展集检验结论是否成立

③ 领域配比建模

- A4–A15 建立 17 域配比 p 与交叉熵 Loss 的定量关系
- 单纯形约束 $p_{\{i\}} \geq 0$ 、 $\sum p_{\{i\}} = 1$ 须合理处理
- A6–A11 检验集验证；A12–A15 讨论外推稳健性
- 是否引入 Q 由队伍论证（经 A16 跨体系映射）

问题一输出 · 供问题二直接使用

域级质量向量 Q_{domain} + 配比模型 $\text{Loss}(p)$

质量评价：22 维指标 → 综合分 Q

预处理 (三步)

- 列表压缩：8 个列表型指标 (fluency、qurater、modernbert 系列等) → 标量化
- 方向统一：负向指标 (广告含量等) Min-Max 后取 $x' = 1 - x$
- 极端值：dsir_* 为大幅负值 → 分位数归一化，避免压扁其余样本

综合评价与聚合

- 赋权：熵权法 / CRITIC 加权求和；PCA 对照验证稳健性
- 聚合：样本级 → 域级 (均值 + 分位数区间)，说明聚合方式
- 对照：A2/A3 扩展集域级 Q 与 A1 抽样一致性检验
- 验证：A18 原始文本抽验评分是否符合直观

综合评分 (熵权法示例)

$$Q = \sum_j w_j \cdot x'_j, \quad w_j = (1 - e_j) / \sum_k (1 - e_k)$$

质量冲突：定义 → 成因 → 消解 → 检验

冲突的数学定义

- 两指标标准化得分之差超过阈值 δ 且方向相反
- δ 依据指标间相关结构确定（比固定常数更有依据）
- 冲突率 = #冲突样本 / #总样本

消解规则

- 内容有效性指标优先；冲突指标对降权；按域分层处理

成因分析（核心洞察）

- 部分"冲突"是文本类型效应，并非真矛盾：
- github 代码句子短、非字母比例高 → 可读性低分 + qurater 内容价值高分
- → 冲突率须按域分层分析，识别结构性来源
- 扩展集（arxiv / github）上检验主要结论是否同样成立

配比建模：单纯形上的 $\text{Loss}(p)$ 模型

成分数据的处理

- p 在 17 维单纯形上: $p_{\{i\}} \geq 0$ 、 $\sum p_{\{i\}} = 1 \rightarrow$ 普通回归不可识别
- 方案一: clr 对数比变换消除闭合效应, 检验后反变换解释
- 方案二: 线性模型去掉一域 + 约束最小二乘 (RegMix 原文思路)

建模与检验

- 线性 + Lasso 正则化选重要域; 交互项考察两域组合效应
- 质量引入: A16 映射 (6 直连 + 11 推断) $\rightarrow$ 对比含 / 不含 Q 的模型
- 检验集 A6–A11: 验证 1M / 60M / 1B 三尺度下的不变性
- 外推表 A12–A15: 稳健性讨论 (外推 Loss 是估算值, 标注可信度)

配比模型 (clr 变换后线性)

$$z = \text{clr}(p), \quad L = a_0 + \sum_i a_i z_i + (\text{可选交互项} + Q \text{ 修正})$$

目标：把 Q、p 纳入标度律 —— 广义标度律

设计约束

- $Q = 1$ 时退化为经典形式（题目鼓励的自然设计）
- A、B 独立但同观测 Loss → 提出可检验假设，统一到同一模型
- Q、p 只来自问题一输出，不重读附件 A 原始文件

数据分工

- B1 主拟合 (1,176 点) B2/B3 族外 / 轨迹验证
- B4/B5 跨族 / 文献验证 B6–B8 唯一含 Q，识别质量效应
- B9/B10 百亿参数以上外推讨论（估算值须标注）

半合成数据局限

B2、B6–B8 基于真实数据校准 + 噪声，
不得表述为直接实验观测
→ 论文中标注可信度边界 + 噪声敏感性分析

广义标度律：质量折算设计

主推形式（质量折算为有效数据量）

$$L(N, D, Q) = E + A \cdot N^{-\alpha} + B \cdot (D \cdot Q^\gamma)^{-\beta}$$

γ 为质量折算指数，由 B6-B8（N-D-Q 网络）识别； $Q = 1$ 时自动退化为经典标度律

退化验证

- $Q = 1 \rightarrow L = E + A \cdot N^{-\alpha} + B \cdot D^{-\beta} \quad \checkmark$

p 的引入与备选方案

- p 经问题一的 $\varphi(p)$ 以加性 / 乘性修正项引入
- 备选：Q 调节幂指数 $\alpha(Q)$ 、Q 折算为有效参数量
- 模型族对比：AIC / BIC / 交叉验证选优，说明依据

估计方法与五级验证链

估计方法

- log-log 变换后线性回归 (Huber 稳健回归抗离群)
- 非线性最小二乘; 按模型族分层随机效应提升稳健性
- 参照先验: Chinchilla $\alpha \approx 0.34$ 、 $\beta \approx 0.28$ 作合理区间

五级验证链

- B1 Pythia 主拟合 $\rightarrow$ B2 Cerebras 族外 $\rightarrow$ B3 插值轨迹
- B4 跨族 57 点 (12 族) $\rightarrow$ B5 文献数据对比
- B9/B10 讨论百亿参数以上的外推行为

单位注意 (实测)

N、D 以十亿计 $\rightarrow C(10^{21} \text{ FLOPs}) = 6 \cdot N_B \cdot D_B \times 10^{-3}$ (B1 中位比值实测 0.001 恰为该换算)

算一笔账：堆参数还是买好教材？

弹性（边际效用）

- 弹性为负：规模、数据、质量提升均使 Loss 下降

$$\varepsilon_N = \partial \ln L / \partial \ln N = -\alpha \cdot A \cdot N^{-\alpha} / (L - E) < 0$$

替代条件（可计算判据）

- 质量提升 0.1 等价于参数增加： $\Delta N \approx -0.1 \cdot (\partial L / \partial Q) / (\partial L / \partial N)$
- 领域替代 / 互补： $\varphi(p)$ 的二阶结构（交互项符号）

$$dN/dQ = -(\partial L / \partial Q) / (\partial L / \partial N)$$

回扣数据墙

- 当“质量换规模”的边际替代比达到临界值，优先提升质量比堆参数更划算 —— 给出该临界条件的解析表达。

算力账本：三部分开销

$$C = 6ND + \overset{\text{总成本}}{D \cdot [g(Q) - g(Q_o)]_+} + \eta \cdot N \cdot D \cdot L_{\text{ctx}}$$

基础训练 (Chinchilla) · 质量提升 (增量成本) · 长文本注意力 ($\eta = 2 \times 10^{-4}$, L_{ctx} 外生依据 C7)

| 质量成本函数 $g(Q)$ (三选一 / 改进)

- 指数型: $\gamma e^{\lambda Q}$ ($\gamma = 10^7$, $\lambda = 6.0$) —— 边际成本陡增
- 幂函数: γQ^{λ} ($\gamma = 5 \times 10^9$, $\lambda = 4.0$)
- 对数渐进: $\gamma \ln(1 + \lambda Q)$ ($\gamma = 2 \times 10^9$, $\lambda = 10.0$) —— 边际递减

| 注意力临界值 (解析给出)

- 上下文达 3 万时, 注意力开销与训练开销相当
- C7 可行值约 2048–32768 → 临界值恰在可行域内, 敏感性分析有实质内容

$$L_{\text{ctx}}^{\text{crit}} = 6/\eta = 3 \times 10^4$$

求解：KKT 解析 + 数值验证

$$\min L(N, D, Q, p) \quad \text{s.t. } C \leq C_{\max}, Q \in (0, 1], p \in \text{单纯形}$$

| 优化模型

- 固定 Q 、 p ：等效成本 $C' = 6ND(1 + \eta L_{\text{ctx}}/6) + D \cdot \Delta g$
- KKT 等边际： $\alpha A \cdot N^{-\alpha} = \beta B \cdot D^{-\beta} \rightarrow N、D$ 最优比例

| Q 与求解策略

- Q 边际条件： $\partial L / \partial Q = \lambda \cdot D \cdot g'(Q) \rightarrow$ 决定 Q 是否拉满
- 指数型 g' 陡增易得内点解；对数型 g' 递减易趋 $Q \rightarrow 1$
- 数值：解析化约 + 一维搜索 + SLSQP 验证； p 取问题一最优配比并论证
- 讨论成本函数选择对最优解的影响（题目明确要求）

预算跨量级：最优策略会质变吗？

$C = 10^{19} / 10^{22} / 10^{24}$ FLOPs (低 / 中 / 高)

三档典型预算

- 转移的数学定义：各资源成本占比随 $\log C$ 的曲线断点 —— 分段回归 + Chow 检验识别
- 或观察 KKT 乘子结构中激活约束集是否改变

预期叙事 ("家庭收入" 类比)

- 低预算：注意力 / 训练开销主导，Q 接近基线
- 中预算：N、D 沿 Chinchilla 比例同步扩张
- 高预算：Q 拉满，质量成本占比显著上升
- 敏感性： L_{ctx} 跨临界值 3×10^4 、三种 $g(Q)$ 形式对比

能力演进：分解贡献 + 前沿预测

综合能力度量

- 6 维 Benchmark 得分简单 / 几何平均（与 Leaderboard 口径一致并说明理由）
- 数据：C1（或 C2）+ C3 时序 + C4 元数据 + C8 逐任务
- 增长分解 + 前沿预测两步走

三个筛选口径（须说明）

- 开源：权重公开、许可证允许研究与复现
- Type 分层：pretrained 与 chat / finetuned 分池
- 时间轴：提交日期为主，说明与发布 / 版本日期偏差
- ⚠ Type 不分层 → 7B 微调与 70B 基座混同，规模效应被混淆

规模扩张 vs 技术进步：增长核算

前沿包络上的增长核算

$$\Delta \ln \text{Cap} = b_N \cdot \Delta \ln N + b_D \cdot \Delta \ln D + b_t \cdot \Delta t + \varepsilon$$

规模贡献 = $b_N \Delta \ln N + b_D \Delta \ln D$ · Solow 余值 ($b_t \Delta t$) = 非规模技术进步 (架构、对齐、数据工程)

方法要点

- 取每个时刻的能力前沿模型 (frontier envelope)
- 面板回归 + 模型族固定效应控制混淆；讨论 N、D 与时间的识别问题

Loss-Benchmark 桥接

- C6 分层：7 条高可比 (Pythia 同验证集) 主拟合，中可比做稳健性验证
- 实测相关系数 ≈ -0.51 ：Loss 越低能力越高 (符合常识)
- 映射误差 (置信带) 显式传播到预测

$$\text{Cap} \approx a - b \cdot (L - E)$$

未来 12/24 个月能力前沿预测

路径 ① 机制路径（主线）

- 算力增长放缓情景下设定 $C(t)$ 曲线
- → 问题三最优配置 → 广义标度律 Loss → 桥接为能力分
- 四问闭环：前文模型全部复用

路径 ② 时序路径（对照）

- 能力前沿序列直接外推：对数线性 / 误差修正
- 不确定性：自举置信区间 + 情景分析 + 蒙特卡洛
- C8 必做：逐任务聚合（如 MATH 单任务演进差异）

讨论

- 评测污染、未来模型未上榜、桥接误差传播 —— 预测区间比点预测更重要。

贯穿全程的五个注意点

规则红线

- 递进耦合：问题二只用问题一输出（不重读 A）；附录附数据利用清单
- 半合成标注：B2、B6–B8、B10、A12–A15 标注性质与可信度边界
- AI 规范：论文末尾披露 AI 工具、使用环节与贡献范围

技术陷阱

- 单位换算： $C(10^{21}) = 6 \cdot N_{\{B\}} \cdot D_{\{B\}} \times 10^{-3}$ ，预算档位换算错误易失分
- 数据说明的"建议"：页脚重复块已实测证伪多处，全部结论自行验证
- 外推表：A12–A15 是估算值，只作稳健性讨论

总结：一条主线，四问闭环

质量 Q 与配比 $p \rightarrow$ 广义标度律 $L(N,D,Q,p) \rightarrow$ 算力最优配置 $\rightarrow$ 能力前沿预测

分工建议：问题一（质量与配比）· 问题二（标度律）· 问题三（优化）· 问题四（前沿）

节奏：四问并行推进 + 中期合稿 + 统一写作模板与代码仓库